



**PROJETO APLICADO I - CURSO BANCO DE DADOS**  
**ANO 2026 - 1º SEMESTRE - TURMA 201825168.000.02A**

**Grupo BD - 2A 2**

- Bruna Sayuri: 10751986
- 10751986@mackenzista.com.br
- Lucas D'Alessandro: 10145549
- 10145549@mackenzista.com.br
- Douglas Augusto Giusti: 10749849
- 10749849@mackenzista.com.br
- Diego Henrique de Moraes: 10753578
- 10753578@mackenzista.com.br

Github: <https://github.com/bdmackgrupo02/Entrega-Final---Grupo-02>

Link para o vídeo: <https://youtu.be/kEi6CtAtm6I>

## Sumário

|                                                           |           |
|-----------------------------------------------------------|-----------|
| <b>1. Glossário.....</b>                                  | <b>2</b>  |
| <b>2. Contexto do estudo e objetivos do trabalho.....</b> | <b>2</b>  |
| <b>3. Cronograma.....</b>                                 | <b>3</b>  |
| <b>4. Apresentação da Empresa: Apple Inc.....</b>         | <b>4</b>  |
| <b>5. A Apple e os ODS.....</b>                           | <b>4</b>  |
| <b>6. Apresentação dos metadados.....</b>                 | <b>5</b>  |
| <b>8. Proposta Analítica e Abordagem estatística.....</b> | <b>7</b>  |
| <b>9. Análise Exploratória de Dados.....</b>              | <b>8</b>  |
| 9.1. Estatística descritiva e tratamento de dados.....    | 8         |
| 9.2. Outputs da análise complementar.....                 | 10        |
| <b>10. Resultados Pretendidos.....</b>                    | <b>14</b> |
| <b>11. Considerações Finais.....</b>                      | <b>15</b> |
| <b>12. Esboço do Storytelling.....</b>                    | <b>15</b> |
| <b>13. ANEXOS.....</b>                                    | <b>16</b> |

## 1. Glossário

**Chave Primária (Primary Key):** Em um BD (Banco de dados), é um identificador único e exclusivo para cada registro dentro de uma tabela. No contexto do trabalho, é representada pela coluna `sale_id`, para que nenhum usuário seja confundido com outro.

**CSV (Comma-Separated Values):** É um formato de arquivo simplificado que armazena dados tabulares contendo texto puro, onde cada valor é separado por uma vírgula. É o formato utilizado no dataset.

**Dashboard:** É uma ferramenta visual que concentra dados complexos em gráficos simples para facilitar a tomada de decisões rápidas. Ela organiza e exibe informações importantes sobre um projeto, negócio ou processo.

**Dataset:** Um conjunto de dados estruturados. No trabalho, refere-se ao arquivo que extraímos do site Kaggle contendo as informações da empresa Apple Inc.

**Float:** Valores que contém casas decimais.

**Gap:** É o que acontece quando você precisa responder a uma pergunta de negócio, mas os dados necessários estão faltando ou que não foram coletados.

**Integer:** Valores que não contém casas decimais, números inteiros

**Kaggle:** O Kaggle é uma plataforma de aprendizagem e competição para cientistas de dados. Utilizamos o dataset da empresa Apple a partir deste site.

**Metadados:** são de forma essencial, “dados sobre dados”. Elas fornecem contexto, estrutura e informações detalhadas sobre um arquivo, imagem, página web ou documento.

**ODS:** Objetivos de Desenvolvimento Sustentável (ou ODS) são uma coleção de 17 metas globais, estabelecidas pela Assembleia Geral das Nações Unidas e o Conselho Econômico das Nações Unidas.

**Storytelling:** É a forma no qual usamos os dados frios para contar histórias. Para a Apple o storytelling não é apenas publicidade. É uma ferramenta central para vender um estilo de vida, gerar conexão emocional e fixar valores de marca.

## 2. Contexto do estudo e objetivos do trabalho

Esse trabalho tem como finalidade a análise de dados da empresa Apple Inc, empresa multinacional norte-americana e seu grande volume de informações geradas pela plataforma. O estudo foi realizado a partir de um *dataset* disponibilizado na plataforma Kaggle composto por conjunto de dados que simula um livro-razão global de vendas realista dos produtos da Apple Inc. Ele abrange transações em nível de cidade em múltiplos continentes, moedas, canais de venda e dados demográficos de clientes — sendo ideal

para análises de varejo, segmentação de mercado, análise de preços, previsão de séries temporais e visualização geográfica.

O objetivo principal é transformar esse monte de informação em resultados fáceis de entender. Além da análise dos dados, o trabalho também envolve a organização das informações, a realização de análises exploratórias e a construção de resultados que possam ser interpretados de forma clara. Queremos descobrir, por exemplo, como a receita evoluiu ao longo do tempo, quais produtos geram mais receita, entre outros.

Em suma, o projeto aplica metodologias de tratamento de dados e análise estatística descritiva para filtrar as informações mais relevantes, permitindo uma compreensão clara, objetiva e estratégica do desempenho comercial da empresa.

### 3. Cronograma

O cronograma foi realizado no **Google Sheets** com o objetivo de designar as tarefas de acordo com os membros da equipe, suas atribuições e responsabilidades, com prazo de entrega de cada tarefa.

| Etapa                            | Atividades Principais                                                                          | Entrega                                 | Responsável                        |
|----------------------------------|------------------------------------------------------------------------------------------------|-----------------------------------------|------------------------------------|
| Entendimento do negócio          | Definição da empresa, objetivos, área de atuação, descrição dos dados e criação do GitHub      | Documento Inicial + link do GitHub      | Lucas D'Alessandro/Diego de Moraes |
| Entendimento dos dados           | Explorar dados, analisar estrutura e identificar oportunidades                                 | Análise inicial dos dados               | Grupo                              |
| Preparação dos dados             | Organização dos dados: limpeza, criação de colunas, tratar campos nulos...                     | Dataset tratado                         | Douglas Giusti                     |
| Análise exploratória e Modelagem | Identificação de padrões e tendências, comparação de variáveis, elaborar os primeiros gráficos | Análise e entrega de scripts via GitHub | Douglas Giusti                     |
| Storytelling                     | Definir narrativa dos dados, suas ordens e organizar insights para a apresentação              | Esboço do storytelling                  | Bruna Yoshiwara                    |
| Dashboard                        | Dashboard com KPI's e gráficos                                                                 | Dashboard pronto                        | Bruna Yoshiwara                    |
| Avaliação                        | Revisão e validação de dados e análises, ajuste de inconsistências                             | Revisão final                           | Grupo                              |
| Apresentação final               | Gravação e entrega do vídeo                                                                    | Entrega final do projeto                | Grupo                              |

*Figura 1: Cronograma por Atividades*

| Etapa                            | 30 dias | 60 dias | 90 dias | 120 dias |
|----------------------------------|---------|---------|---------|----------|
| Entendimento do negócio          |         |         |         |          |
| Entendimento dos dados           |         |         |         |          |
| Preparação dos dados             |         |         |         |          |
| Análise exploratória e Modelagem |         |         |         |          |
| Storytelling                     |         |         |         |          |
| Dashboard                        |         |         |         |          |
| Avaliação                        |         |         |         |          |
| Apresentação final               |         |         |         |          |

*Figura 2: Cronograma por Etapas*

#### 4. Apresentação da Empresa: Apple Inc

A Apple Inc. é uma empresa multinacional norte-americana fundada em 1976, com sede em Cupertino, Califórnia. Ela atua no desenvolvimento, fabricação e comercialização de produtos eletrônicos, softwares e serviços digitais, destacando-se pela forte integração entre seus produtos. Seu portfólio inclui smartphones, computadores, tablets, dispositivos vestíveis e acessórios, além de sistemas operacionais próprios e uma ampla oferta de serviços digitais, como distribuição de aplicativos, streaming, armazenamento em nuvem, meios de pagamento e suporte técnico. A empresa opera em escala global, com presença física e digital em dezenas de países, atendendo mercados das Américas, Europa, China, Japão e Ásia-Pacífico.

Do ponto de vista econômico e mercadológico, a Apple está entre as maiores empresas do mundo em faturamento, com receitas anuais superiores a US\$390 bilhões e valor de mercado na casa dos trilhões de dólares. O segmento de serviços dessa empresa apresenta crescimento contínuo e altas margens de lucro, mas é no seu produto mais icônico, o iPhone, que possui sua principal fonte de renda. Além disso, a empresa possui uma base instalada superior a 2 bilhões de dispositivos ativos globalmente, o que evidencia uma ampla base de clientes e elevado grau de fidelização. Esse desempenho é sustentado por um modelo de negócios baseado em inovação, marca forte e um ecossistema integrado, que reforça sua competitividade e liderança no setor de tecnologia.

#### 5. A Apple e os ODS

O foco da Apple está conectada diretamente a pilares fundamentais da Agenda de 2030 da ONU:

- **ODS 7 e 13:** Energia Limpa e Acessível e Ação Contra a Mudança Global do Clima  
A empresa atua com eletricidade 100% renovável em suas instalações corporativas e possui mais de 110 fornecedores mundiais comprometidos para transicionar para energia limpa.
- **ODS 12:** Consumo e Produção Responsáveis
  - A Apple trabalha ativamente para que as caixas de seus produtos tenham fibras de papel em suas composições para eliminar plásticos, e criam também, produtos com alto índice de materiais que poderão ser reciclados.
- **ODS 9:** Indústria, Inovação e Infraestrutura
  - investem também em robótica (como o robô Daisy) para recuperar materiais valiosos e utilizá-los na cadeia produtiva.
- **ODS 17:** Parcerias e Meios de Implementação
  - A Apple atua em conjunto com ONGs e fundos ambientais focados em reflorestamento e restauração de ecossistemas ao redor do mundo.

## 6. Apresentação dos metadados

Origem (Kaggle):

<https://www.kaggle.com/datasets/ashyou09/apple-global-product-sales-dataset>

Colaborador: Ashutosh Singh (Dono do CSV)

Área: Tecnologia / Índice de Vendas/produto.

Formato do Arquivo: CSV

Codificação: UTF-8

Separador: , (vírgula)

Tamanho do arquivo: 2.41 MB

Licença: MIT

Período de Coleta: 31/12/2021 à 30/12/2024.

Total de Linhas: 11.500 (transações de vendas sintéticas para iPhone, iPad, Mac, Apple Watch, AirPods e acessórios)

### **Total de Colunas: 27**

- **sale\_id** (id da venda) [varchar]  
Identificador de venda atribuído a cada nova venda.
- **sale\_date** (período da compra) [datetime]  
Período no qual foi realizado a compra
- **Year** (ano) [integer]  
Ano em que foi concretizado a compra (2022-2024)
- **Quarter** (trimestre) [varchar]  
Qual trimestre foi realizado a compra (Q1-Q4)
- **Month** (mês) [varchar]  
Mês atribuído a compra (Janeiro-Dezembro)
- **Country** (país) [varchar]  
País no qual foi realizado a compra (47 no total)
- **Region** (região) [varchar]  
Região no qual foi feito a compra do produto (5 no total)
- **City** (cidade) [varchar]  
Cidade da compra (Cidades dentro dos 47 países)

- **product\_name** (nome do produto) [varchar]  
Nome do produto
- **Category** (categoria) [varchar]  
Identificador de qual categoria a venda pertence:  
iPhone  
Accessories (Acessórios)  
Mac  
iPad  
Apple Watch
- **Storage** (armazenamento) [varchar]  
Qual o armazenamento do produto comprado
- **Color** (cor) [varchar]  
Cor do produto
- **unit\_price\_usd** (valor do produto) [float]  
Valor unitário do produto
- **discount\_pct** (desconto) [float]  
Foi aplicado algum desconto
- **units\_sold** (unidades vendidas) [integer]  
Unidades vendidas
- **discounted\_price\_usd** (valor com desconto) [float]  
Preço com desconto aplicado
- **revenue\_usd** (preço total com desconto) [float]  
Preço total com desconto
- **Currency** (moeda) [varchar]  
Qual moeda utilizada para pagamento
- **fx\_rate\_to\_usd** (taxa de câmbio) [float]  
Taxa de Câmbio para o Dólar
- **revenue\_local\_currency** (valor convertido) [float]  
Valor convertido para moeda local
- **sales\_channel** (canal de venda) [varchar]  
Canal de Venda (no total 5)
- **payment\_method** (método de pagamento) [varchar]  
Método do pagamento (no total 5)

- **customer\_segment** (segmento do cliente) [varchar]  
Em qual segmento este cliente pertence (no total 4)
- **customer\_age\_group** (idade do grupo do cliente) [varchar]  
Em qual grupo este cliente pertence (18-55+)
- **previous\_device\_os** (sistema operacional anterior) [varchar]  
Qual o sistema operacional do aparelho anterior a compra
- **customer\_rating** (nota do cliente) [float]  
Qual a nota que o cliente fornece pela compra (1-5)
- **return\_status** (status de retorno) [varchar]  
Qual a taxa de retorno, sendo  
Kept: Ficou com o produto  
Returned: comprou, mas se arrependeu da compra  
Exchange: troca por outro produto.

## 7. Conclusão sobre os metadados

A partir da compreensão estrutural do dataset e da exploração inicial dos metadados, identificamos diversas oportunidades práticas para extrair insights valiosos sobre o funcionamento da organização. O detalhamento do comportamento de venda dos usuários nos permite ir além dos números básicos e entender a fundo a relação entre o público e a empresa.

Filtrando as possibilidades que mais se alinham aos objetivos de negócio da Apple e à nossa proposta de estudo, selecionamos seis frentes principais de análise que consideramos as mais estratégicas para o desenvolvimento deste projeto:

- Desempenho e Receita: Faturamento Total, crescimento de vendas ao longo do tempo.
- Produtos e Portfólio: Quais categorias vendem mais (iPhone, Mac, Ipad, e entre outros)
- Geografia: Desempenho de venda por regiões mundiais (Ao redor do planeta)
- Perfil do Cliente: Comportamentos de compra, idade dentre outros.
- Preço, Desconto e Valor Percebido: Impacto de descontos, preços, tíquete médio.
- Qualidade e Retorno: Taxas de devolução, Classificação da venda (1-5).

## 8. Proposta Analítica e Abordagem estatística

A proposta analítica deste projeto consiste na realização de uma Análise Exploratória de Dados (EDA) com o objetivo de:

1. Compreender a estrutura e a qualidade dos dados;
2. Identificar padrões de comportamento de vendas;



3. Analisar relações entre variáveis financeiras, temporais, geográficas e comportamentais;
4. Servir como base para análises preditivas ou prescritivas futuras.
5. A abordagem adotada é descritiva e diagnóstica, levantando hipóteses e insights iniciais, sem buscar estabelecer causalidade.

## 9. Análise Exploratória de Dados

A seguir serão apresentados os outputs do código elaborado, incluindo a análise estatística, o tratamento de dados e todas as análises complementares utilizadas no estudo. Cabe a ressalva de que na seção de anexos também estão apresentados os outputs e código utilizado, o qual também está postado no github do grupo.

### 9.1. Estatística descritiva e tratamento de dados

A análise exploratória foi conduzida a partir de estatísticas descritivas, ferramentas gráficas e análises segmentadas. O código foi desenvolvido em notebook python, utilizando as bibliotecas pandas e numpy.

Inicialmente, foi realizado o carregamento do dataset e a tradução dos cabeçalhos das colunas para o português. Em seguida, foram realizados alguns tratamentos dos dados, como a limpeza de cabeçalhos duplicados e a conversão do tipo de dados, como foi o caso da coluna referente à data de venda. Além disso, foi realizada a verificação dos valores ausentes, com a identificação das colunas que possuem esse problema. Para facilitar a visualização, o grupo gerou um gráfico mostrando a proporção de valores ausentes em cada coluna, conforme indica a figura 3.




Figura 3: Proporção de valores ausentes por Coluna

Dessa forma, consideramos alguns critérios para preencher as linhas faltantes, por meio de ferramentas estatísticas:


- Para nota dos clientes, preenchemos com a mediana das notas;
- Para o armazenamento dos aparelhos, preenchemos com “N/A”;
- Para o aparelho anterior, preenchemos com “Desconhecido”.

Além disso, o grupo aplicou uma análise estatística descritiva geral para as colunas numéricas, conforme segue na figura 4.

|       | preco    | desconto | unidades_venda | receita  | nota_cliente |
|-------|----------|----------|----------------|----------|--------------|
| count | 11500.00 | 11500.00 | 11500.00       | 11500.00 | 11500.00     |
| mean  | 807.85   | 3.84     | 2.02           | 1568.32  | 4.00         |
| std   | 1112.44  | 4.78     | 1.44           | 2839.76  | 0.48         |
| min   | 26.69    | 0.00     | 1.00           | 23.00    | 3.00         |
| 25%   | 180.15   | 0.00     | 1.00           | 305.74   | 3.70         |
| 50%   | 593.90   | 2.00     | 1.00           | 833.04   | 4.00         |
| 75%   | 958.39   | 7.00     | 3.00           | 1748.36  | 4.30         |
| max   | 7551.01  | 15.00    | 8.00           | 59529.52 | 5.00         |


*Figura 4: Análise estatística descritiva geral*

O grupo também gerou uma visualização da distribuição das principais variáveis numéricas envolvidas no dataset, conforme a figura 5.



*Figura 5: Distribuição das Variáveis Numéricas*

Um destaque interessante pode ser dado para a nota do cliente, que se concentra em 4.0/5.0, conforme destacado por gráfico na figura 6.



*Figura 6: Distribuição da Nota do Cliente*

Assim, o grupo realizou as análises complementares que serão apresentadas a seguir, com as devidas observações e alguns indicativos.

## **9.2. Outputs da análise complementar**

### **a) Análise Temporal**

A evolução da receita ao longo dos anos e trimestres evidenciou padrões de crescimento e possíveis efeitos sazonais, indicando períodos de maior concentração de vendas conforme a figura 7.




Figura 7: Evolução da Receita ao Longo do Tempo

### b) Análise de Produtos e Categorias

Observou-se que a receita é fortemente concentrada em determinadas categorias e produtos, enquanto outras apresentam maior volume de vendas com ticket médio reduzido, sugerindo estratégias complementares de portfólio.





Figura 8: Proporção de valores ausentes na base

### c) Análise Geográfica


A análise por país revelou maior concentração de receita em alguns países, com destaque para Hong Kong, Holanda e México, evidenciando a importância de determinados países para o desempenho financeiro global da empresa, conforme gráfico gerado apresentado na figura 9.



*Figura 9: Top 10 Países por Receita Total*

#### d) Perfil do Cliente

Os resultados indicam que o comportamento de compra varia mais significativamente por segmento de cliente do que por faixa etária, reforçando a relevância da segmentação para estratégias comerciais.



*Figura 10: Perfil do Cliente Apple*




Figura 11: Frequência das Variáveis Categóricas

### e) Preço, Desconto e Satisfação

A relação entre desconto, receita e satisfação do cliente mostrou que descontos elevados não são necessariamente determinantes para altos níveis de satisfação ou receita, sugerindo forte influência do valor percebido do produto.





Figura 12: Satisfação e Política de Descontos

### f) Qualidade e Retorno

A taxa de retorno dos produtos mostrou-se relativamente baixa, o que, aliado às boas avaliações de satisfação, indica alinhamento entre a expectativa do cliente e entrega do produto.



*Figura 13: Status de Retorno por Categoria (%)*

No intuito de sintetizar a análise até aqui apresentada, o grupo gerou um resumo das principais informações obtidas na presente análise, conforme apresentado na figura 14:

| RESUMO DA ANÁLISE EXPLORATÓRIA |                    |
|--------------------------------|--------------------|
| Receita Total:                 | US\$ 18,035,669    |
| Total de Vendas:               | 11,500 transações  |
| Produto mais lucrativo:        | Mac Pro (M2 Ultra) |
| País com maior receita:        | Hong Kong          |
| Canal mais frequente:          | Online (Apple.com) |
| Nota média dos clientes:       | 4.00 / 5.0         |
| Taxa de retorno/troca:         | 11.8%              |

*Figura 14: Resumo da Análise Exploratória*

## 10. Resultados Pretendidos

A partir desta análise exploratória, espera-se que o projeto contribua para:

- Melhor compreensão dos fatores que influenciam a geração de receita;
- Apoio à tomada de decisão estratégica baseada em dados;
- Identificação de oportunidades de melhoria em precificação, segmentação e portfólio;
- Fundamentação para análises futuras, como modelos preditivos de receita, clusterização de clientes ou análise de elasticidade de preço.

## **11. Considerações Finais**

A Análise Exploratória de Dados demonstrou-se essencial para transformar dados brutos em informações relevantes, reduzindo a dependência de decisões baseadas exclusivamente em intuição e fortalecendo uma cultura orientada por dados.

Pelas aplicações utilizadas, o grupo pôde entender pontos interessantes, tais como a receita evoluiu ao longo do tempo dentro do período estudado, quais anos e trimestres concentraram o maior faturamento a existência de concentração de receita em poucos produtos e se a faixa etária influencia o faturamento. Assim, essas informações podem servir como base para dar continuidade a estudos futuros na área da análise de dados.

## **12. Esboço do Storytelling**

- a) Apresentação do grupo e nome do projeto;
- b) Introdução e Contextualização;
- c) Empresa / Organização de estudo;
- d) Área do Problema e o Gap Identificado;
- e) Dados disponíveis;
- f) Proposta analítica e EDA;
- g) Resultados Pretendidos e Insights das Visualizações;
- h) Conclusão do Roteiro.



## 13. ANEXOS

```
[5]: # PROJETO APLICADO I - CURSO BANCO DE DADOS
# ANO 2026 - 1º SEMESTRE - TURMA 201825168.000.02A
# 1.IMPORTAÇÃO DE BIBLIOTECAS

import pandas as pd
import numpy as np

# importação do dataset
df = pd.read_csv('dataset_grupo2.csv')
df.head()

# Para Visualização dos gráficos o grupo importou essas bibliotecas
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns

# Configurações gerais de visualização dos gráficos
sns.set_theme(style='whitegrid', palette='muted')
plt.rcParams['figure.dpi'] = 120
plt.rcParams['figure.figsize'] = (10, 5)
plt.rcParams['font.family'] = 'DejaVu Sans'

# Impedir avisos desnecessários
import warnings
warnings.filterwarnings('ignore')

print("-----")
print(' Bibliotecas importadas com sucesso!')
print("-----")

-----
Bibliotecas importadas com sucesso!
-----
```

```
[6]: # 2. TRADUÇÃO DOS CABEÇALHOS PARA PORTUGUÊS
# Dicionário de tradução das colunas

colunas_pt = {
    'sale_id'           : 'codigo_venda',
    'sale_date'         : 'data_venda',
    'year'              : 'ano',
    'quarter'          : 'trimestre',
    'month'             : 'mes',
    'country'           : 'pais',
    'region'            : 'regiao',
    'city'              : 'cidade',
    'product_name'      : 'produto',
    'category'          : 'categoria',
    'storage'           : 'armazenamento',
    'color'             : 'cor',
    'unit_price_usd'    : 'preco_usd',
    'discount_pct'      : 'desconto_pct',
    'units_sold'        : 'unidades_vendidas',
    'discounted_price_usd' : 'preco_com_desconto_usd',
    'revenue_usd'       : 'receita_usd',
    'currency'          : 'moeda',
    'fx_rate_to_usd'    : 'taxa_cambio',
    'revenue_local_currency' : 'receita_moeda_local',
    'sales_channel'     : 'canal_venda',
    'payment_method'    : 'metodo_pagamento',
    'customer_segment'  : 'segmento_cliente',
    'customer_age_group' : 'faixa_etaria',
    'previous_device_os' : 'aparelho_anterior',
    'customer_rating'   : 'nota_cliente',
    'return_status'     : 'status_retorno'
}

df.rename(columns=colunas_pt, inplace=True)
print("-----")
print('Colunas renomeadas para português:')
print("-----")
for i, col in enumerate(df.columns, start=1):
    print(f'{i}. {col}')

-----
Colunas renomeadas para português:
-----
1. codigo_venda;data_venda;ano;quartil;mes;pais;regiao;cidade;nome_produto;categoria;armazenamento;cor;preco;desconto;unidades_venda;preco_com_descont
o;receita;moeda;taxa_usd;faturamento_moeda_local;canal_venda;metodo_pagamento;seguimento_cliente;faixa_etaria_cliente;aparelho_anterior;nota_cliente;st
atus_retorno
```

```
[61]: # 3. TRATAMENTO DOS DADOS - TIPOS DE DADOS
# Converter data_venda para tipo datetime

# Verificar se a primeira linha de dados contém valores de cabeçalho duplicados
# Isso é indicado pela string 'sale_date' na coluna 'data_venda'
if not df.empty and df.iloc[0]['data_venda'] == 'sale_date':
    print("Identificado e removendo linha extra que contém cabeçalhos repetidos.")
    df = df.iloc[1:].copy()
    df.reset_index(drop=True, inplace=True)

df['data_venda'] = pd.to_datetime(df['data_venda'], dayfirst=True)

# Confirmar conversão dos dados
print("-----")
print(f'Tipo da coluna data_venda: {df["data_venda"].dtype}')
print(f'Período do dataset: {df["data_venda"].min().date()} até {df["data_venda"].max().date()}')
print("-----")

Identificado e removendo linha extra que contém cabeçalhos repetidos.

Tipo da coluna data_venda: datetime64[ns]
Período do dataset: 2022-01-01 até 2024-12-31
-----
```

```
[7]: # 4. TRATAMENTO DOS DADOS - VALORES AUSENTES
# Contagem e percentual de nulos por coluna
nulos = df.isnull().sum()
pct_nulos = (nulos / len(df) * 100).round(2)

resumo_nulos = pd.DataFrame({
    'Qtd. Nulos' : nulos,
    'Percentual (%)': pct_nulos
}).query('`Qtd. Nulos` > 0').sort_values('Qtd. Nulos', ascending=False)

print("-----")
print('Colunas com valores ausentes:')
display(resumo_nulos)
print("-----")
```


```
Colunas com valores ausentes:
   Qtd. Nulos  Percentual (%)
-----
```

```
[63]: # TRATAMENTO DOS DADOS - VALORES AUSENTES → VISUALIZAÇÃO
fig, ax = plt.subplots(figsize=(8, 4))

bars = ax.barh(
    resumo_nulos.index,
    resumo_nulos['Percentual (%)'],
    color=['#e74c3c' if v > 50 else '#e67e22' if v > 20 else '#f1c40f' for v in resumo_nulos['Percentual (%)']]
)

# Rótulos nas barras
for bar, val in zip(bars, resumo_nulos['Percentual (%)']):
    ax.text(bar.get_width() + 0.5, bar.get_y() + bar.get_height()/2,
            f'{val:.1f}%', va='center', fontsize=10)

ax.set_xlabel('% de Valores Ausentes')
ax.set_title('Proporção de Valores Ausentes por Coluna', fontweight='bold', pad=12)
ax.set_xlim(0, 100)
plt.tight_layout()
plt.show()
```



```
[64]: # VALORES AUSENTES → TRATAMENTO

# 'armazenamento': ~42% nulo → faz sentido para categorias sem variação de storage, como airpods, accessories e apple watch. Colocamos 'N/A'
df['armazenamento'].fillna('N/A', inplace=True);

# 'aparelho_anterior': ~78% nulo → coluna com poucos dados válidos. Colocamos 'Desconhecido' para manter a linha na nossa base.
df['aparelho_anterior'].fillna('Desconhecido', inplace=True);

# 'nota_cliente': ~29% nulo → valores numéricos. Colocamos a mediana nos casos ausentes
# Converter a coluna para numérico primeiro, forçando erros para NaN
df['nota_cliente'] = pd.to_numeric(df['nota_cliente'], errors='coerce');
mediana_nota = df['nota_cliente'].median();
df['nota_cliente'].fillna(mediana_nota, inplace=True);

# Converter outras colunas numéricas para o tipo apropriado
numeric_cols_to_convert = ['preco', 'desconto', 'unidades_venda', 'preco_com_desconto', 'receita', 'taxa_usd', 'faturamento_moeda_local'];
for col in numeric_cols_to_convert:
    # Verifica se a coluna existe no DataFrame para evitar KeyError em caso de inconsistência de nomes
    if col in df.columns:
        df[col] = pd.to_numeric(df[col], errors='coerce');

print("-----")
print('\n Verificação pós-tratamento:');
print(df.isnull().sum()[df.isnull().sum() > 0]);
print(' → Nenhum valor ausente restante.' if df.isnull().sum().sum() == 0 else '');
print("-----")
```

```
Verificação pós-tratamento:
Series([], dtype: int64)
 → Nenhum valor ausente restante.
-----
```

```
[65]: # 5. ANÁLISE ESTATÍSTICA
# Aplicamos estatística descritiva de colunas numéricas

df[['preco', 'desconto', 'unidades_venda',
    'receita', 'nota_cliente']].describe().round(2)
```

```
[65]:
```

|       | preco    | desconto | unidades_venda | receita  | nota_cliente |
|-------|----------|----------|----------------|----------|--------------|
| count | 11500.00 | 11500.00 | 11500.00       | 11500.00 | 11500.00     |
| mean  | 807.85   | 3.84     | 2.02           | 1568.32  | 4.00         |
| std   | 1112.44  | 4.78     | 1.44           | 2839.76  | 0.48         |
| min   | 26.69    | 0.00     | 1.00           | 23.00    | 3.00         |
| 25%   | 180.15   | 0.00     | 1.00           | 305.74   | 3.70         |
| 50%   | 593.90   | 2.00     | 1.00           | 833.04   | 4.00         |
| 75%   | 958.39   | 7.00     | 3.00           | 1748.36  | 4.30         |
| max   | 7551.01  | 15.00    | 8.00           | 59529.52 | 5.00         |

```
[66]: # DISTRIBUIÇÃO DAS VARIÁVEIS NUMÉRICAS PRINCIPAIS


variaveis = ['preco', 'desconto', 'unidades_venda', 'receita', 'nota_cliente']
titulos = ['Preço (USD)', 'Desconto (%)', 'Unidades Vendidas', 'Receita (USD)', 'Nota do Cliente']

fig, axes = plt.subplots(2, 3, figsize=(15, 8))
axes = axes.flatten()


for i, (col, titulo) in enumerate(zip(variaveis, titulos)):
    sns.histplot(df[col], ax=axes[i], kde=True, color='steelblue', bins=30)
    axes[i].set_title(titulo, fontweight='bold')
    axes[i].set_xlabel('')
    axes[i].set_ylabel('Frequência')

# Ocultar o subplot extra
axes[-1].set_visible(False)

fig.suptitle('Distribuição das Variáveis Numéricas', fontsize=14, fontweight='bold', y=1.01)
plt.tight_layout()
plt.show()
```



```
[67]: # DISTRIBUIÇÃO DA NOTA DO CLIENTE
fig, ax = plt.subplots(figsize=(8, 5))
sns.histplot(df['nota_cliente'], ax=ax, kde=True, color='purple', bins=10)
ax.set_title('Distribuição da Nota do Cliente', fontweight='bold')
ax.set_xlabel('Nota do Cliente (0-5)')
ax.set_ylabel('Frequência')
plt.tight_layout()
plt.show()
```




```
[68]: # ANÁLISE DAS VARIÁVEIS CATEGÓRICAS
# Frequência das principais variáveis categóricas
categorias = {
    'categoria'      : 'Categoria de Produto',
    'canal_venda'     : 'Canal de Venda',
    'seguimento_cliente' : 'Segmento de Cliente',
    'faixa_etaria_cliente' : 'Faixa Etária', # Corrected column name
    'metodo_pagamento' : 'Método de Pagamento',
    'status_retorno'   : 'Status de Retorno'
}

fig, axes = plt.subplots(2, 3, figsize=(16, 9))
axes = axes.flatten()

paleta = sns.color_palette('muted')

for i, (col, titulo) in enumerate(categorias.items()):
    contagem = df[col].value_counts()
    bars = axes[i].barh(contagem.index, contagem.values,
                        color=paleta[:len(contagem)])
    axes[i].set_title(titulo, fontweight='bold')
    axes[i].set_xlabel('Nº de Vendas')
    # Rótulos
    for bar, val in zip(bars, contagem.values):
        axes[i].text(bar.get_width() + 20, bar.get_y() + bar.get_height()/2,
                     f'{val:,}', va='center', fontsize=8)

fig.suptitle('Frequência das Variáveis Categóricas', fontsize=14, fontweight='bold', y=1.01)
plt.tight_layout()
plt.show()
```




```
[69]: # 6. ANÁLISE TEMPORAL - RECEITA POR ANO E TRIMESTRE
# Receita total por ano
receita_ano = df.groupby('ano')['receita'].sum().reset_index()

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# --- Gráfico 1: Receita por Ano ---
cores = ['#3498db', '#2ecc71', '#e74c3c']
bars = axes[0].bar(receita_ano['ano'].astype(str), receita_ano['receita'] / 1e6,
                  color=cores, width=0.5)
for bar, val in zip(bars, receita_ano['receita']):
    axes[0].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.3,
                f'US$ {val/1e6:.1f}M', ha='center', fontweight='bold')
axes[0].set_title('Receita Total por Ano', fontweight='bold')
axes[0].set_ylabel('Receita (Milhões USD)')
axes[0].set_xlabel('Ano')

# --- Gráfico 2: Receita por Trimestre (agrupado por ano) ---
pivot = df.groupby(['ano', 'quartil'])['receita'].sum().unstack('quartil') / 1e6
pivot.plot(kind='bar', ax=axes[1], colormap='tab10', width=0.7)
axes[1].set_title('Receita por Trimestre e Ano', fontweight='bold')
axes[1].set_ylabel('Receita (Milhões USD)')
axes[1].set_xlabel('Ano')
axes[1].legend(title='Trimestre', bbox_to_anchor=(1, 1))
axes[1].set_xticklabels(pivot.index.astype(str), rotation=0)

plt.suptitle('Evolução da Receita ao Longo do Tempo', fontsize=13, fontweight='bold', y=1.02)
plt.tight_layout()
plt.show()
```



```
[70]: # 7. ANÁLISE DE PRODUTOS – RECEITA E VOLUME POR CATEGORIA
# Receita e unidades vendidas por categoria
resumo_cat = df.groupby('categoria').agg(
    receita_total = ('receita', 'sum'),
    unidades_total = ('unidades_venda', 'sum'),
    ticket_medio = ('receita', 'mean')
).sort_values('receita_total', ascending=False).reset_index()


fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Receita por categoria
sns.barplot(data=resumo_cat, x='receita_total', y='categoria',
            palette='Blues_r', ax=axes[0])
axes[0].set_title('Receita Total por Categoria (USD)', fontweight='bold')
axes[0].set_xlabel('Receita (USD)')
axes[0].set_ylabel('')
axes[0].xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f'{x/1e6:.1f}M'))
for i, val in enumerate(resumo_cat['receita_total']):
    axes[0].text(val + 2e5, i, f'US$ {val/1e6:.1f}M', va='center', fontsize=9)

# Unidades vendidas por categoria
sns.barplot(data=resumo_cat, x='unidades_total', y='categoria',
            palette='Greens_r', ax=axes[1])
axes[1].set_title('Unidades Vendidas por Categoria', fontweight='bold')
axes[1].set_xlabel('Unidades Vendidas')
axes[1].set_ylabel('')
for i, val in enumerate(resumo_cat['unidades_total']):
    axes[1].text(val + 50, i, f'{val:,}', va='center', fontsize=9)

plt.suptitle('Desempenho por Categoria de Produto', fontsize=13, fontweight='bold', y=1.02)
plt.tight_layout()
plt.show()

print("-----")
print('\n Resumo por Categoria:')
print("-----")
resumo_cat['receita_total'] = resumo_cat['receita_total'].map('US$ {:.0f}'.format)
resumo_cat['ticket_medio'] = resumo_cat['ticket_medio'].map('US$ {:.0f}'.format)
display(resumo_cat.rename(columns={
    'categoria' : 'Categoria',
    'receita_total' : 'Receita Total',
    'unidades_total' : 'Unidades Vendidas',
    'ticket_medio' : 'Ticket Médio'
}))
```



```
[71]: # 8. ANÁLISE GEOGRÁFICA – TOP 10 PAÍSES POR RECEITA
# Ranking dos 10 países com maior receita

top_paises = (df.groupby('pais')['receita']
               .sum()
               .sort_values(ascending=False)
               .head(15)
               .reset_index())


fig, ax = plt.subplots(figsize=(10, 6))

cores_paises = ['#2c3e50' if i == 0 else '#3498db' if i < 3 else '#85c1e9'
                for i in range(len(top_paises))]

bars = ax.barh(top_paises['pais'][::-1], top_paises['receita'][::-1] / 1e6,
               color=cores_paises[::-1])

for bar, val in zip(bars, top_paises['receita'][::-1]):
    ax.text(bar.get_width() + 0.1, bar.get_y() + bar.get_height()/2,
            f'US$ {val/1e3:.0f}k', va='center', fontsize=9)

ax.set_xlabel('Receita (Milhões USD)')
ax.set_title('Top 10 Países por Receita Total', fontweight='bold', pad=12)
plt.tight_layout()
plt.show()
```





```
[72]: # 9. ANÁLISE DO PERFIL DO CLIENTE
# Receita por faixa etária e segmento de cliente

fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# --- Faixa Etária ---
faixa_receita = (df.groupby('faixa_etaria_cliente')['receita']
                .sum()
                .sort_index()
                .reset_index())

sns.barplot(data=faixa_receita, x='faixa_etaria_cliente', y='receita',
            palette='Purples_r', ax=axes[0])
axes[0].set_title('Receita por Faixa Etária', fontweight='bold')
axes[0].set_xlabel('Faixa Etária')
axes[0].set_ylabel('Receita (USD)')
axes[0].yaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f'{x/1e6:.1f}M'))

# --- Segmento de Cliente ---
seg_receita = (df.groupby('segmento_cliente')['receita']
              .sum()
              .sort_values(ascending=False)
              .reset_index())

wedges, texts, autotexts = axes[1].pie(
    seg_receita['receita'],
    labels=seg_receita['segmento_cliente'],
    autopct='%1.1f%%',
    colors=sns.color_palette('pastel'),
    startangle=140)
axes[1].set_title('Receita por Segmento de Cliente', fontweight='bold')

plt.suptitle('Perfil do Cliente Apple', fontsize=13, fontweight='bold', y=1.01)
plt.tight_layout()
plt.show()
```



```
[73]: # 10. ANÁLISE DE DESCONTO E SATISFAÇÃO
# Desconto médio e nota média por categoria


resumo_satisf = df.groupby('categoria').agg(
    desconto_medio = ('desconto', 'mean'),
    nota_medio      = ('nota_cliente', 'mean')
).round(2).sort_values('nota_medio', ascending=False).reset_index()

fig, axes = plt.subplots(1, 2, figsize=(13, 5))

# Nota média por categoria
sns.barplot(data=resumo_satisf, x='nota_medio', y='categoria',
            palette='YlOrRd_r', ax=axes[0])
axes[0].set_xlim(3.5, 4.5)
axes[0].set_title('Nota Média por Categoria', fontweight='bold')
axes[0].set_xlabel('Nota Média (0-5)')
axes[0].set_ylabel('')
for i, val in enumerate(resumo_satisf['nota_medio']):
    axes[0].text(val + 0.01, i, f'{val:.2f}', va='center', fontsize=9)

# Desconto médio por categoria
sns.barplot(data=resumo_satisf.sort_values('desconto_medio', ascending=False),
            x='desconto_medio', y='categoria', palette='Blues_r', ax=axes[1])
axes[1].set_title('Desconto Médio por Categoria (%)', fontweight='bold')
axes[1].set_xlabel('Desconto Médio (%)')
axes[1].set_ylabel('')
for i, val in enumerate(resumo_satisf.sort_values('desconto_medio', ascending=False)['desconto_medio']):
    axes[1].text(val + 0.05, i, f'{val:.1f}%', va='center', fontsize=9)

plt.suptitle('Satisfação e Política de Descontos', fontsize=13, fontweight='bold', y=1.01)
plt.tight_layout()
plt.show()
```



```
[76]: # 11. TAXA DE RETORNO DOS PRODUTOS
# Status de retorno geral


retorno_geral = df['status_retorno'].value_counts(normalize=True).mul(100).round(2)

print('-- Distribuição de Status de Retorno:')
for status, pct in retorno_geral.items():
    print(f'    {status:>10}: {pct:.1f}%')

# Taxa de retorno por categoria
retorno_cat = (df.groupby(['categoria', 'status_retorno'])
               .size()
               .unstack(fill_value=0))
retorno_cat_pct = retorno_cat.div(retorno_cat.sum(axis=1), axis=0).mul(100).round(1)

fig, ax = plt.subplots(figsize=(11, 5))
retorno_cat_pct.plot(kind='barh', stacked=True,
                    colormap='RdYlGn_r', ax=ax)
ax.set_title('Status de Retorno por Categoria (%)', fontweight='bold', pad=12)
ax.set_xlabel('Proporção (%)')
ax.set_ylabel('')
ax.legend(title='Status', bbox_to_anchor=(1.01, 1))
plt.tight_layout()
plt.show()

-- Distribuição de Status de Retorno:
    Kept: 88.2%
    Returned: 7.8%
    Exchanged: 4.0%
```



```
[75]: # RESUMO DOS INSIGHTS DA EDA

receita_total = df['receita'].sum()
produto_top = df.groupby('nome_produto')['receita'].sum().idxmax()
pais_top = df.groupby('pais')['receita'].sum().idxmax()
canal_top = df['canal_venda'].value_counts().idxmax()
nota_geral = df['nota_cliente'].mean()
taxa_retorno = (df['status_retorno'] != 'Kept').mean() * 100

print("-----")
print('          RESUMO DA ANÁLISE EXPLORATÓRIA')
print("-----")
print(f' | Receita Total:           US$ {receita_total:,.0f}')
print(f' |')
print(f' | Total de Vendas:         {len(df):,} transações')
print(f' |')
print(f' | Produto mais lucrativo:   {produto_top}')
print(f' |')
print(f' | País com maior receita:   {pais_top}')
print(f' |')
print(f' | Canal mais frequente:     {canal_top}')
print(f' |')
print(f' | Nota média dos clientes:   {nota_geral:.2f} / 5.0')
print(f' |')
print(f' | Taxa de retorno/troca:    {taxa_retorno:.1f}%')
print("-----")
```

```
-----
RESUMO DA ANÁLISE EXPLORATÓRIA
-----
| Receita Total:           US$ 18,035,669
| Total de Vendas:         11,500 transações
| Produto mais lucrativo:   Mac Pro (M2 Ultra)
| País com maior receita:   Hong Kong
| Canal mais frequente:     Online (Apple.com)
| Nota média dos clientes:   4.00 / 5.0
| Taxa de retorno/troca:    11.8%
-----
```